Veri Bilimi
Otomatik Veri Çekme (Python)

M. Fuat Kına

https://socialcomquant.ku.edu.tr/

SOCIAL COMQUANT

Veri Bilimi Nedir?

- Veri bilimi, yapılandırılmış veya kirli olarak mevcut bulunan herhangi bir bilgiyi kullanarak elimizdeki toplam bilgiyi arttırmaya veya analiz etmeye yarayan interdisipliner bir alandır.
- İstatistik ve programlamanın kesişiminde hayat bulmuş olsa da birçok açıdan matematikten ve geniş anlamda bilgisayar bilimlerinden faydalanır.
- Veri madenciliği, makine öğrenmesi, yapay zeka, büyük veri…

Veri Bilimi Uygulama Alanları

- Sınıflandırma ve kategorizasyon
- Tahmine dayalı modelleme
- Duygu ve davranış analizi
- Öneri motorları ve kişiselleştirme sistemleri
- Konuşma sistemleri
- Anomali tespiti
- Kalıp (örüntü) tanımlama
- Otonom sistemler

Veri Bilimi ve Sosyal Bilimler

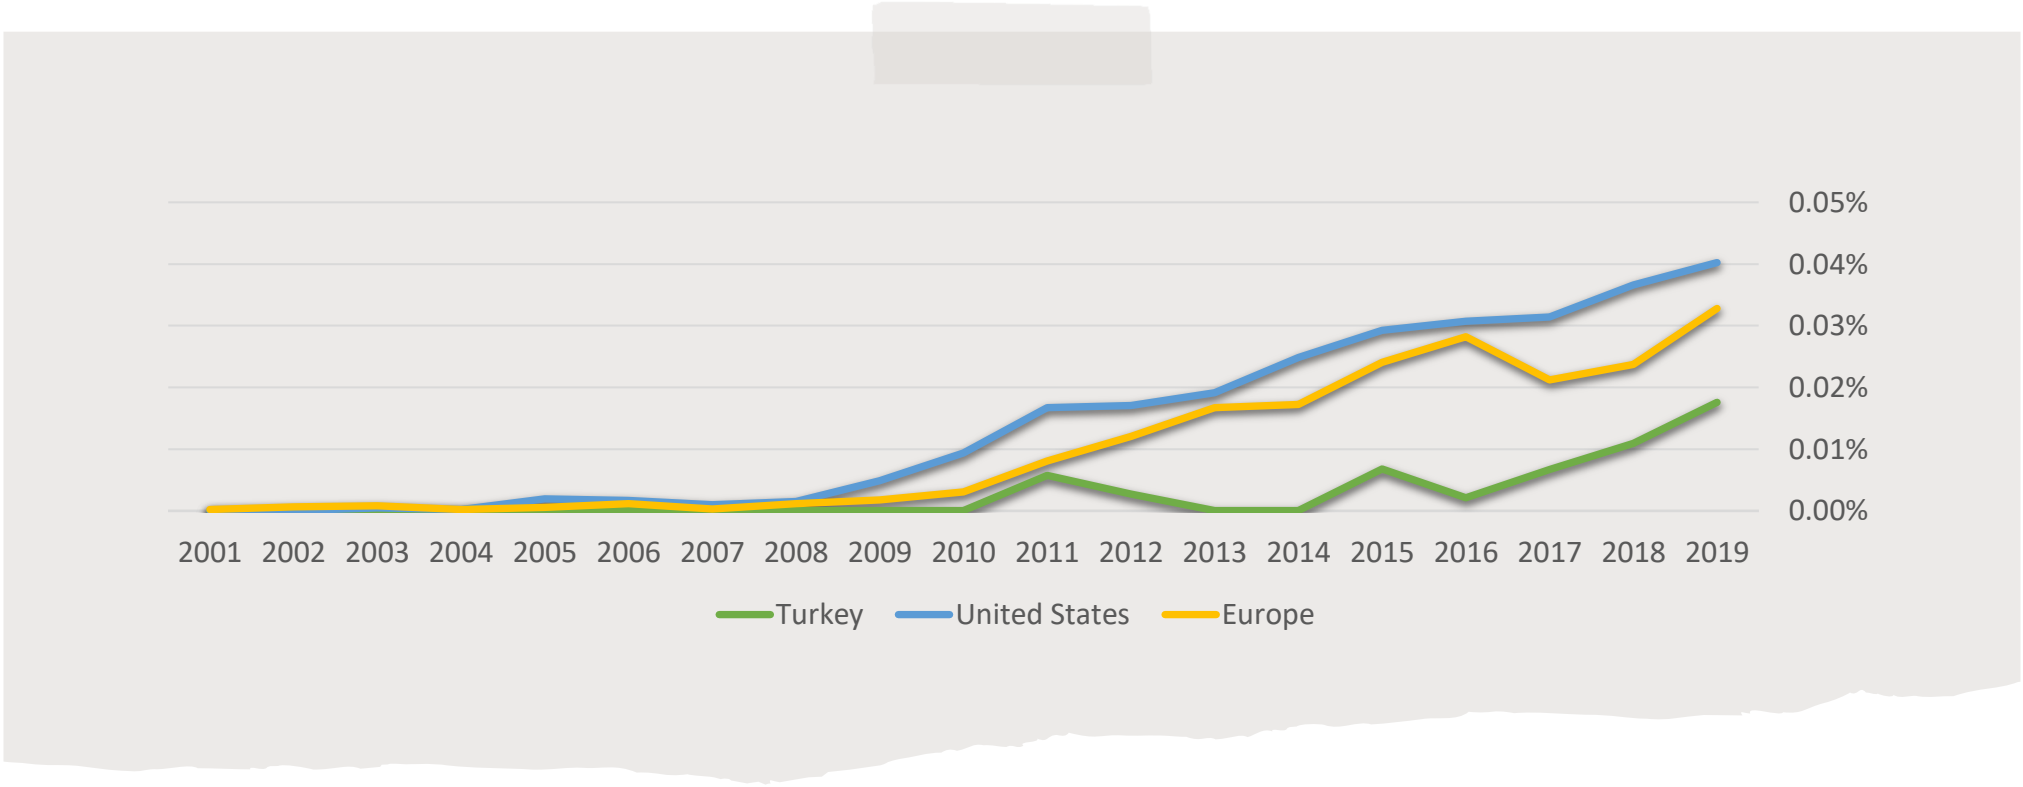

Hesaplamalı Sosyal Bilimler

- Metin Analizi (NLP)
- Coğrafi Bilgi Sistemleri
- Network Analizi
- Veri oluşturma (e.g. toplumsal hareketler, yoksulluk, göçmen karşıtlığı)

Veri Analizinin Aşamaları

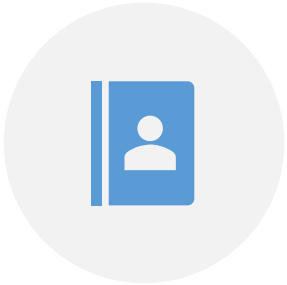

Veri oluşturma: çekme, toplama, sıfırdan yaratma

Temizleme ve önişleme

Analiz: model kurma, regresyon, sınıflandırma

Modelin test edilmesi ve kullanılması: tahmin, optimizasyon, nedensellik, vb.

Veri oluşturma

- Hazır veri setleriyle çalışmak: World Bank, OECD, GLOCON, TÜİK, etc.
- Uygulama programlama arayüzü (application programing interface): Sosyal medya, mesajlaşma uygulamaları
- Veri kazıma
- İleri veri oluşturma teknikleri: Yapay zeka, makine öğrenmesi, vb.

Uygulama programlama arayüzü (API)

- API’lar Web sitesi operatörleri tarafından sağlanır.
- Erişim limitleri (kullanıcı onaylama, kullanım sınırları)

Sosyal medya

- Facebook (https://developers.facebook.com/)
- Twitter (https://developer.twitter.com/en/docs)
- YouTube (https://developers.google.com/youtube/v3)
- Flickr (https://www.flickr.com/services/api/)
- Reddit (https://www.reddit.com/dev/api/)
- LinkedIn (https://www.linkedin.com/developers/)
- Mesaj uygulamaları: Telegram, WhatsApp, Threema, Skype, Discord
- Akış uygulamaları: Spotify, Apple Music, Vimeo, Twitch
- Diğer servisler: Google Maps, Amazon, Wikipedia

Twitter API

- Kolay erişilebilir
- Zengin veri içeriği
- Retweet, favori, takipçi sayıları, tweet içeriği, biyografi, profil fotoğrafı, vb.
- Academic API, ayda 10 milyon tweet sağlıyor.

Zorluklar:

- Gerçek insanların hesaplarından emin olmak zor
- Bu kişilerin kim olduğu hakkında bilgi eksikliği
- Platforma özgü limitler

Python'da ilgili kütüphane (tweepy)

Twitter API

```
# tweepy kütüphanesini çağırın
import tweepy as tw

# Twitter API key ve API secret bilgilerini tanımlayın
my_api_key = "MY_API_KEY"
my_api_secret = "MY_API_SECRET"

# kimlik doğrulama
auth = tw.OAuthHandler(my_api_key, my_api_secret)
api = tw.API(auth, wait_on_rate_limit=True)

search_query = "computational social science -filter:retweets"

tweets = api.search_tweets(q = search_query, lang = "en", count = 1000)
```

Veri kazıma

- Sayfayı ve HTML kodunu didikle
- URL’yi (linki) tanımla, ve HTML sayfasını indir
- HTML kodlarını böl, parçala
- İlgili içeriği çıkart
- Veriyi yaz/kaydet

Python'da ilgili kütüphane (scrapy)

HTML yapısı

- html = elements + attributes + text
  - Hypertext markup language
  - Çocuk, ebeveyn, kardeş, gelecek kuşaklar…

```
<html>
    <body>
        <div id="div1" class="class-1">
            <p class="class-1 class-2">Hello World!</p>
            <p>Data Science!</p>
        </div>
    </body>
</html>
```

Some HTML-Elements

Metadata:

<head> collection of metadata

<title> title of the document

Sections:

<body> main contents of the document

<section> section of the document

<h1>, <h2>, … headlines

Grouped Contents

 container

<p> paragraph

Links

<a> Hyperlink, refers via href-attribute to resource

Lists

 unordered list

 ordered list

 entry of a list

Tables

<table> table

<tr> row of a table

<td> cell of a table

Xpath

Html dosyasını Scrapy ile ayrıştırma

Sunumun bu noktadan sonraki kısmında yer alan kodlar için takip eden kaynaktan faydalandım: https://app.datacamp.com/learn/courses/web-scraping-with-python

- / → Bir nesil ileri git
- [] → Aradığımız elemanın sıralmasını belirt
- // → Tüm gelecek kuşaklar içinde ilerle

- *Xpath = '/html/body/div[2]//table'*

Head elemanını altındaki body elemanını altındaki ikinci div elemanının altındaki tüm tabloları seçer.

Xpath

Bazı örnekler:

- '//p’
- ‘/head/body//div’
- ‘/div[3]//p’

Özellik seçimi:

- Xpath = '//span[@class="span-class"]’

Class özelliği ‘span_class’ olan tüm span elemanlarını seçer.

Xpath

Örnek! ‘Data Science’ kelime grubunu seç.

```
html =
'''<html>
  <body>
    < div>
      <p>Hello World!</p>
      <div>
        <p>Data Science!</p>
      </div>
    </div>
    <div>
      <p>Thanks for Watching!</p>
    </div>
  </body>
</html>'''
```

Herhangi bir elemanın tüm çocuklarını seç:

- *Xpath = ‘/html/body/*’*

Body elemanını altındaki tüm gelecek kuşakları seç:

- *Xpath = "/html/body//*"*

HTML dökümanındaki tüm elemanları seç:

- *Xpath = "//*“*

Artık *, /, //, [], @ kullanarak, eleman veya nitelik arayarak ilgili yolu belirtebiliriz.

Not: Doğrudan eşleştirme yerine birden çok nesne içeren özellikler için (örneğin <p class = 'class1 class2'>) içerme fonksiyonunu (“contain”) kullanabiliriz.

Xpath

Örnek:

```
html = '''
<html>
 <body>
  <div id="div1" class="class-1">
   <p class="class-1 class-2">Hello World!</p>
   <div id="div2">
    <p id="p2" class="class-2">Choose
      <a href ="http://datascience.com">Data Science!</a>!
    </p>
   </div>
  </div>
  <div id="div3" class="class-2">
   <p class="class-2">Thanks for Watching!</p>
  </div>
 </body>
</html>’‘
```

"Thanks for Watching!" ifadesini içeren paragraf öğesini seçelim

- Xpath = /html/body//div[2]/p
- Xpath = //div[@id=“div3”]/p

“Hello World!" ifadesini içeren paragraf öğesini seçelim

- Xpath = /html/body/div/p
- Xpath = //p[@class=“class-1 class-2”]

“Data Science” hiper linki için ilgili bölümün href özelliğini seçelim (elemanın değil özelliğin içeriğini almak istediğimizi unutmayın)

- Xpath = /html/body/div/div/p/a/@href

veya

- Xpath = //a/@href

Xpath ile metin çekme

```
<p id="p-example">
  Hello world!
  Try <a href="http://www.datacamp.com">DataCamp</a> today!
</p>
```

- In XPath use `text()`

```
sel.xpath('//p[@id="p-example"]/text()').extract()
# result: ['\n Hello world!\n Try ', ' today!\n']
```

```
sel.xpath('//p[@id="p-example"]//text()').extract()
# result: ['\n Hello world!\n Try ', 'DataCamp', ' today!\n']
```

Scrapy

```
# Scrapy kütüphanesinden Selector metodunu çağırın
from scrapy import Selector

# requests kütüphanesini indirin
import requests

url = 'https://m.imdb.com/chart/top'

# HTML kaynağını içeren html string'ini oluşturun
html = requests.get(url).content

# html objesini kullanarak bir Selector objesi tanımlayın
sel = Selector(text = html)

# ilgili xpath'i tanımlayın
xpath_for_movienames ='//h4/text()'

# ve aradığınız metin grubunu çekin!
sel.xpath(xpath_for_movienames).extract()
```

Spider

```
import scrapy
from scrapy.crawler import CrawlerProcess

class IMDB_Spider(scrapy.Spider):
    name = "IMDB_Spider"

    def start_requests(self):
        yield scrapy.Request(url = 'https://m.imdb.com/chart/top',
                             callback = self.parse_front)

    def parse_front(self, response):

        movie_names = response.xpath('//h4/text()').extract()
```

Pratik uygulama: veri kazıma ve API kullanımı